

Previsão de Sucesso em Acompanhamento Nutricional Personalizado

Relatório Técnico de Inteligência Artificial e Ciência de Dados

André Fazendeiro 48191 e Manuel Moura 52333

Universidade da Beira Interior

Licenciatura em Inteligência Artificial e Ciência de Dados

Conteúdo

1 Introdução 3

2 Fase 1: Integração de Dados 3

3 Fase 2: Limpeza e Processamento de Dados 3

4 Fase 3: Análise Exploratória de Dados (EDA) 4

5 Fase 4: Identificação de Padrões (Clustering) 4

6 Fase 5: Aplicação de Modelos de Previsão 5

7 Fase 6: Discussão Crítica de Resultados 6

8 Conclusão 6

1 Introdução

A prevalência de patologias crónicas associadas a hábitos alimentares inadequados tem impulsionado a procura por estratégias de nutrição personalizada. No entanto, a predição do sucesso clínico (traduzido pela perda ponderal) é altamente complexa, dado o envolvimento multifatorial de variáveis biológicas, clínicas e comportamentais.

Este trabalho aborda o ciclo completo de Ciência de Dados sobre um histórico clínico composto por 2523 programas de intervenção nutricional. O objetivo principal consiste em integrar dados fragmentados, aplicar técnicas rigorosas de limpeza, conduzir uma análise exploratória (EDA), segmentar perfis de pacientes via algoritmos de clustering e desenvolver modelos preditivos de aprendizagem supervisionada para estimar o sucesso terapêutico a 6 meses.

2 Fase 1: Integração de Dados

A base de dados original encontrava-se fragmentada em quatro ficheiros no formato CSV: *patients.csv*, *diets.csv*, *nutritionists.csv* e *outcomes.csv*.

A estratégia de integração tomou o ficheiro *outcomes.csv* como a tabela factual central (2523 registos), que interliga as instâncias de acompanhamento. Utilizando a biblioteca Pandas, procedeu-se à junção das tabelas através de operações de *inner merge* mapeadas pelas chaves relacionais em formato snake case:

- Resultados com Planos: Ligados através da chave *diet_id*.
- Resultados com Pacientes: Ligados através da chave *patient_id*.
- Resultados com Nutricionistas: Ligados através da chave *nutritionist_id*.

O Quadro 1 detalha a volumetria inicial evidenciada pelo terminal antes do processo de unificação, cujo resultado final culminou num dataset consolidado de dimensões (2523, 31).

Tabela 1: Dimensões Iniciais dos Ficheiros Fontes

Dataset	Linhas	Colunas
Pacientes (patients.csv)	1000	11
Planos de Dieta (diets.csv)	10	9
Nutricionistas (nutritionists.csv)	20	5
Resultados Clínicos (outcomes.csv)	2523	9

3 Fase 2: Limpeza e Processamento de Dados

Os dados brutos integrados continham ruído sistémico que exigiu intervenção orientada pelos princípios de qualidade de dados:

- **Remoção de Características Redundantes:** Identificou-se colunas duplicadas que violavam o princípio da parcimónia. As variáveis *bmi_redundant* (cópia de *baseline_bmi*) e *experience_years* (cópia de *years_experience*) foram inteiramente dropadas, reduzindo a dimensionalidade para 29 colunas.
- **Padronização Categórica:** A variável *approach* continha falhas de introdução de texto (ex: 'Strict', 'strict' e 'empathetic '). Aplicou-se uma transformação para uniformizar todas as strings em minúsculas e removeu-se espaços em branco periféricos (trimming).
- **Tratamento de Outliers:** Detetou-se que o nutricionista N008 registava erroneamente 99.0 anos de experiência profissional. Por constituir um outlier severo capaz de distorcer os modelos, o valor foi substituído de forma robusta pela mediana dos profissionais ativos (≤ 60 anos).
- **Imputação de Valores em Falta (Missing Values):** O diagnóstico inicial reportou lacunas cruciais em dados fisiológicos e comportamentais (ex: 254 nulos em *fiber_target_g*, 143 em *age*). Optou-se pela estratégia de imputação pela mediana para variáveis numéricas por se apresentar imune à influência de assimetrias. Nas variáveis categóricas em falta, imputou-se pela moda. A lista final foi estendida para abranger a idade (*age*), resultando num dataset limpo final com 0 valores nulos restantes.

4 Fase 3: Análise Exploratória de Dados (EDA)

A análise estatística descritiva e os cruzamentos de dados geraram insights cruciais sobre a eficácia das intervenções. Ao avaliar o impacto do tipo de dieta na alteração ponderal ao fim de 6 meses (*weight_change_kg_6m*), observou-se uma assimetria no desempenho das abordagens.

Tabela 2: Eficácia Média da Alteração de Peso por Tipo de Dieta

Tipo de Dieta	Média de Alteração de Peso (kg)
Balanced (Equilibrada)	-21.02
High Protein (Hiperproteica)	-21.19
Plant Based (Vegetariana/Vegan)	-21.46
Low Carb (Baixo Teor de Hidratos)	-23.66

Conforme apresentado no Quadro 2, as dietas com restrição de hidratos de carbono (Low Carb) demonstraram uma performance superior na perda de peso médio, atingindo -23.66 kg. As restantes abordagens mantiveram-se homogéneas, fixando-se em torno dos -21 kg.

Os gráficos gerados na pasta *graficos/* (como os diagramas de caixa por sexo e tipo de dieta e os diagramas de dispersão de adesão) validaram visualmente que a adesão contínua do paciente (*mean_adherence_pct*) e as métricas motivacionais mantêm uma

forte correlação linear com o sucesso da perda de peso.

5 Fase 4: Identificação de Padrões (Clustering)

Com o intuito de mapear subgrupos homogêneos de pacientes, aplicou-se o algoritmo não supervisionado K-Means. As características selecionadas para o agrupamento focaram-se no perfil físico, comportamental e no desfecho (*age*, *baseline_weight_kg*, *sleep_hours*, *mean_adherence_pct* e *weight_change_kg_6m*). Os dados foram normalizados preventivamente via *StandardScaler*.

Através do Método do Cotovelo (Elbow Method), identificou-se $K = 3$ como o número ideal de aglomerados, ponto onde a inércia intracluster (WCSS) exibe uma inflexão abrupta. O perfil médio calculado para cada segmento clínico gerou as seguintes definições (Quadro 3):

Tabela 3: Caracterização dos Perfis de Pacientes Obtidos via K-Means

Cluster	Idade Média	Peso Inicial	Sono (h)	Adesão (%)	Resultado (6m)
0	31.64	78.00 kg	7.17 h	84.99%	-27.37 kg (Máximo Sucesso)
1	44.45	72.62 kg	7.03 h	59.52%	-13.97 kg (Sucesso Baixo)
2	57.03	75.54 kg	6.89 h	84.72%	-21.56 kg (Sucesso Sólido)

- **Cluster 0 — Jovens Focados:** Faixa etária jovem, maior tempo de repouso e adesão máxima ao plano (85%), resultando numa expressiva perda de peso de -27.37 kg.
- **Cluster 1 — Incumpridores:** Pacientes de idade intermédia com falhas de adesão severas (59.5%), retendo o pior desempenho clínico (-13.97 kg).
- **Cluster 2 — Seniores Resilientes:** Grupo de idade avançada que, apesar de demonstrar o mesmo nível de compromisso e adesão (84.7%) que o Cluster 0, apresenta uma perda ligeiramente menor (-21.56 kg), um comportamento clinicamente expectável devido à desaceleração metabólica natural do envelhecimento.

6 Fase 5: Aplicação de Modelos de Previsão

Com a incorporação da coluna *cluster_paciente* como variável preditiva, formulou-se um problema de aprendizagem supervisionada para regressão da variável alvo contínua *weight_change_kg_6m*. O dataset foi dividido em 80% para treino e 20% para teste.

Construiu-se um pipeline robusto com codificação One-Hot para variáveis categóricas e escalonamento para numéricas. Foram confrontados dois algoritmos de famílias distintas: a **Regressão Linear** e o **Random Forest Regressor**. O desempenho avaliado no conjunto de teste encontra-se exposto no Quadro 4.

Tabela 4: Métricas de Avaliação dos Modelos Preditivos

Modelo	RMSE (kg)	R-Squared (R ²)
Regressão Linear	7.9596	0.3298
Random Forest Regressor	6.8513	0.5034

7 Fase 6: Discussão Crítica de Resultados

O comportamento comparativo dos modelos preditivos evidencia que a natureza do problema é inerentemente não-linear. A Regressão Linear obteve uma performance modesta ($R^2 = 0.33$), sendo incapaz de capturar interações cruzadas entre características como o efeito combinado da idade e da motivação do paciente.

Por outro lado, o algoritmo baseado em ensembles de árvores de decisão — Random Forest — demonstrou uma superioridade clara, explicando 50.34% da variabilidade dos dados com uma redução expressiva do erro médio residual para 6.85 kg (RMSE). A introdução da classificação comportamental oriunda do algoritmo K-Means atuou como um forte catalisador preditivo.

Contudo, subsiste uma fatia de 50% da variância não explicada por nenhum dos modelos. Esta limitação decorre de restrições intrínsecas aos dados disponíveis no ambiente real de saúde:

- **Variáveis Omitidas:** O dataset não possui registos de atividade física diária (exercício aeróbico vs. anaeróbico), taxa metabólica basal medida por bioimpedância ou marcadores genéticos predisponentes.
- **Subjetividade e Viés:** Os scores de adesão e motivação são frequentemente autorreportados pelos pacientes, estando sujeitos ao viés de desejabilidade social (sobrealegalção de cumprimento do plano).

Como trabalho futuro, recomenda-se a integração de dispositivos vestíveis (wearables) para recolha automatizada de gastos calóricos e padrões reais de sono, minimizando o ruído de dados reportados.

8 Conclusão

O projeto percorreu com sucesso todas as etapas da metodologia de Ciência de Dados. Provou-se empiricamente a eficácia superior de dietas Low Carb para perda de peso rápida, mapearam-se três perfis clínicos distintos cruciais para a triagem e selecionou-se um modelo preditivo baseado em Random Forest que confere aos profissionais de saúde e gestores de clínicas uma ferramenta fiável para antever o prognóstico de sucesso do paciente, otimizando recursos e prevenindo a taxa de abandono terapêutico.